

Bases de Données Avancées
Exploration et SQLite
RAPPORT 1

Felipe Mateus Falcão Barreto

1. Étude de cas et des données utilisées

L'objectif principal de ce projet est de développer une plateforme web permettant la consultation avancée de films. À cette fin, la base de données IMDB a été mise à disposition. 11 fichiers CSV ont ainsi été utilisés pour une première analyse des données fournies:

- `movies.csv` - Films (identifiant, titre, année, durée)
- `persons.csv` - Personnes (acteurs, réalisateurs, scénaristes)
- `characters.csv` - Personnages joués par les acteurs
- `directors.csv` - Relations film ↔ réalisateur
- `genres.csv` - Genres associés aux films
- `knownformovies.csv` - Film principal de chaque personne
- `principals.csv` - Acteurs/réalisateurs principaux d'un film
- `professions.csv` - Profession de chaque personne
- `ratings.csv` - Notes moyennes et nombre de votes
- `titles.csv` - Titres dans différentes langues/régions
- `writers.csv` - Scénaristes des films

1.1 Objectifs

L'objectif est de comprendre la structure et la qualité des données IMDB, de concevoir un schéma relationnel normalisé, de maîtriser les requêtes SQL de complexité variable et d'optimiser les performances des requêtes à l'aide d'index.

1.2 Résumé de l'exploration (observations clés, graphiques)

Para realizar a análise, foi criado o arquivo `data/exploration.ipynb` que contém as seguintes análises:

- Nombre de lignes et colonnes de chaque tableau
 - `characters` - lignes: 152898, colonnes: 3
 - `directors` - lignes: 40933, colonnes: 2
 - `genres` - lignes: 85426, colonnes: 2
 - `knownformovies` - lignes: 252924, colonnes: 2
 - `movies` - lignes: 36859, colonnes: 8
 - `persons` - lignes: 145847, colonnes: 4
 - `principals` - lignes: 361863, colonnes: 5
 - `professions` - lignes: 318014, colonnes: 2
 - `ratings` - lignes: 36859, colonnes: 3
 - `titles` - lignes: 775705, colonnes: 8
 - `writers` - lignes: 82857, colonnes: 2
- Types de données - object, int64 et float64
- Valeurs manquantes (NaN, chaînes vides)
 - `movies`: 36899 des valeurs manquantes
 - `persons`: 204137 des valeurs manquantes
 - `principals`: 252305 des valeurs manquantes
 - `professions`: 3235 des valeurs manquantes
 - `titles`: 1510606 des valeurs manquantes
- Valeurs uniques par colonne

- movies mid - 36859 des valeurs uniques
- persons pid - 145847 des valeurs uniques

- Histogrammes

- Distribution des films par année
- Top 10 des genres les plus fréquents
- Distribution des notes (ratings)
- Nombre moyen d'acteurs par film - 4.04 acteurs par film

- Vérifier les clés étrangères et identifier les données orphelines


5 personnes dans la table characters ne sont pas enregistrées dans la table persons

5 personnes dans la table principals ne sont pas enregistrées dans la table persons

2 personnes dans la table writers ne sont pas enregistrées dans la table persons

2. Diagramme ER du schéma relationnel

Pour représenter visuellement le schéma de la base de données du système, un diagramme ER du schéma relationnel a été élaboré pour chacune des 11 entités. Les entités movies et persons étant les entités principales du système, elles servent d'identifiants pour les autres. Le diagramme ER ainsi que le tableau des relations et des cardinalités sont présentés ci-dessous.



Relation	Cardinalité
Movies — Characters — Persons	N : N
Movies — Directors — Persons	N : N
Movies — Writers — Persons	N : N
Movies — Principals — Persons	N : N
Movies — KnownForMovies — Persons	N : N
Movies — Genres	1 : N
Movies — Titles	1 : N
Persons — Professions	1 : N

Dans tous les tableaux, les clés primaires des films et des personnes ont été utilisées comme clés étrangères dans le tableau référencé.

3. Les 9 requêtes SQL avec explications

Nessa etapa, foram desenvolvidas 9 consultas sql que exploram relações entre diversas tabelas, permitindo análise de desempenho e popularidade.

- `filmsByActor` - Dans quels films a joué un acteur donné?
- `bestFilmsFilter` - Les N meilleurs films d'un genre sur une période selon la note moyenne
- `charactersByActor` - Acteurs multi-rôles : Acteurs ayant joué plusieurs personnages dans un même film, triés par nombre de rôles
- `filmsTogether` - Réalisateurs ayant travaillé avec un acteur spécifique, avec le nombre de films ensemble
- `bestMoviesMetrics` - Genres ayant une note moyenne >7.0 et plus de 50 films, triés par note
- `bestByDecade` - Pour un acteur donné, nombre de films par décennie avec note moyenne
- `moviesPodium` - Pour chaque genre, les 3 meilleurs films avec leur rang
- `famousByMovie` - Personnes ayant percé grâce à un film, après avoir participé à des films ayant obtenu moins de 200 000 votes, puis à des films ayant obtenu plus de 200 000 votes.
- `top_actors_by_genre` - Pour un genre donné, une liste d'acteurs ayant joué dans au moins deux films de ce genre, classés par note moyenne et par nombre d'apparitions.

4. Tableau de benchmark

Le tableau de benchmark a été généré à partir du script principal qui exécute les requêtes SQL. Ce script effectue les opérations suivantes :

- Se connecte à la base de données SQLite imdb.db
- Définit les paramètres de test pour l'exécution de chaque requête avec et sans les index créés, afin de mesurer le temps d'exécution initial et optimisé.
- Affiche un tableau comparatif indiquant le temps d'exécution de chaque requête en ms et le gain en pourcentage.

Ce tableau permet d'identifier les requêtes qui bénéficient le plus de la création d'index, offrant ainsi une analyse de performance claire.

5. Index créés et justifications

- `idx_q1_persons_primaryName`
Utilisé dans la colonne `primaryName` de la table `persons`. Permet de rechercher des acteurs par leur nom, y compris les recherches case-insensitive, évitant ainsi une analyse complète de la table.
- `idx_q1_principals_pid_mid`
Utilisé dans les colonnes `pid` et `mid` de la table `principals`. Accélère les jointures entre les tables `persons` et `principals` pour récupérer les films d'un acteur.

- `idx_q2_genres_genre_mid`
Utilisé dans les colonnes `genre` et `mid` du tableau des genres. Permet de filtrer rapidement les films par genre spécifique.
- `idx_q2_movies_startYear_mid`
Utilisé dans les colonnes `startYear` et `mid` de la table `movies`. Facilite les requêtes par plage d'années.
- `idx_q2_ratings_mid`
Utilisée dans la colonne `mid` du tableau `ratings`. Optimise les jointures pour obtenir les notes moyennes des films filtrées par genre et par année.
- `idx_q3_characters_pid_mid`
Utilisé dans les colonnes `pid` et `mid` de la table `characters`. Accélère les requêtes vérifiant plusieurs rôles pour un acteur dans un même film.
- `idx_q4_directors_pid_mid`
Utilisé dans les colonnes `pid` et `mid` du tableau `directors`. Facilite la recherche de collaborations entre réalisateurs et un acteur spécifique.
- `idx_q5_genres_mid`
Utilisé dans la colonne `mid` du tableau `genres`. Optimise les jointures avec les notes pour calculer les moyennes par genre.
- `idx_q5_ratings_mid`
Utilisée dans la colonne `mid` du tableau `ratings`. Permet un accès rapide aux notes des films regroupées par genre.
- `idx_q6_principals_pid_mid`
Utilisé dans les colonnes `pid` et `mid` de la table `principals`. Accélère les requêtes sur la carrière d'un acteur par décennie.
- `idx_q7_genres_mid`
Utilisé dans la colonne `mid` de la table `genres`. Facilite l'identification des films par genre pour calculer le classement ou le podium.
- `idx_q8_principals_pid`
Utilisé dans la colonne `pid` de la table `principals`. Optimise les requêtes sur l'historique des films d'un acteur pour détecter une carrière propulsée.
- `idx_q8_movies_mid`
Utilisé dans la colonne `mid` de la table `movies`. Permet d'accéder rapidement aux informations des films lors des jointures avec `principals` et `ratings`.
- `idx_q8_ratings_mid`
Utilisé dans la colonne `mid` de la table `ratings`. Accélère le calcul des votes avant et après un tournant dans la carrière d'un acteur.
- `idx_q9_genres_genre_mid`
Utilisé dans les colonnes `genre` et `mid` de la table `genres`. Facilite les requêtes complexes impliquant plusieurs jointures pour trouver les acteurs par genre.
- `idx_q9_principals_mid`
Utilisé dans la colonne `mid` de la table `principals`. Permet un croisement rapide des films avec les acteurs dans des requêtes libres.